ICSI230 Машин сургалт хичээл: даалгавар 1

Дасгал 1: Машины үнийг таамаглах

Сургалтын зорилго

1. Бодит амьдралын асуудлыг ML-ийн ойлголт/тусгал болгон хөрвүүлэх
2. Тэдгээр ойлголтыг зөв математик тэмдэглэгээгээр илэрхийлэх

Та хуучин автомашины дилер дээр ажилладаг бөгөөд компанийн чинь боломжийн үнээр худалдан авч болох худалдаанд байгаа тээврийн хэрэгслүүдийг олж тогтоох даалгавартай гэж төсөөл. Та энэ сорилтыг өгөгдөлд суурилсан байдлаар шийдэхээр шийдэж, автомашины шинж чанаруудаас нь (features) тохирох зах зээлийн үнийг (EUR) таамагладаг загвар боловсруулна.

- Өгөгдсөн даалгаврыг тодорхойл: чиглүүлэгтэй (supervised) эсвэл чиглүүлэггүй (unsupervised) юу? Регресс үү эсвэл ангилал (classification) уу? “Тайлбарлахын тулд суралцах” уу эсвэл “таамаглахын тулд суралцах” уу? Хариултаа үндэслэлийн хамт бич.

- *Supervised сургалт ашиглана. Яагаад гэвэл output буюу гаралт нь тодорхой утгатай буюу тоон утга байна*
- *Регресс ашиглана. Яагаад гэвэл гаралтын утга бодит тоон утга байх буюу ангилалуудад хуваах шаардлагагүй*
- *Тайлбарлахын тулд суралцаж байгаа. Яагаад гэвэл машинуудын ямар features тухайн машины үнэд хамгийн их нөлөөлж байгааг олох ашигтай.*

- Өгөгдлөө хэрхэн зохион байгуулах вэ? Боломжит шинжүүд (features)-ийг тус бүрийн өгөгдлийн төрөл (data type)-тэй нь нэрлээд, зорилтот хувьсагч (target variable)-ийг тодорхойл.

- *Өгөгдлийг хүснэгт хэлбэрээр, мөр бүр нэг машины талаарх мэдээлэл, эхний бүлэг багануд харгалзах шинж чанарууд ба сүүлийн багана тухайн машины үнийн мэдээллийг хадгалана.*
- *Боломжит шинж чанарууд:*
  - *Марк – Categorical – Toyota, Nissan, Ford, BMW, Mercedes Benz*
  - *Үйлдвэрлэсэн огноо – Numerical – 2010*
  - *Туулсан зам – Numerical – 30000 (км)*
- *Зорилтот хувьсагч:*
  - *Үнэ – Numerical – 30000 EUR*

- Одоо тээврийн хэрэгслийн нас (өдөр), явсан зай (км), үнэ (EUR)-ийн өгөгдөл байгаа гэж үзье. Онцлогийн олонлог X болон таамаглаг олонлог Y-г тодорхой илэрхийл.

- *X = [(Age, Distance)] # X[0] = (3650, 10000)*
- *Y = Price # Y[0] = 3000*

Та энэ даалгаварт шугаман загвар (Linear Model, LM) ашиглахаар сонголоо. LM нь зорилтот хувьсагчийг онцлогуудын шугаман функц бөгөөд алдаа нь Гауссын тархалттай (Gaussian error term) гэж үзнэ.

- Холбогдох загварын ангиллын таамаглалын олонлог (hypothesis space)-г тодорхойл. Үүний тулд параметрийн вектор θ нь огтлолцлын коэффициент (intercept coefficient)-ийг агуулна гэж үз.

- $H = \{ f \mid f((x_1, x_2)) = w_0 + w_1x_1 + w_2x_2;\ x_1, x_2 \in X,\ w_0, w_1, w_2 \in \theta \}$
- x_1 = *нас*
- x_2 = *туулсан зам*
- w_0, w_1, w_2 = *хувьсагч болгоны коэффициент*

- Ямар параметрүүдийг суралцах (learn) шаардлагатай вэ? Холбогдох параметрийн орон зай θ-г тодорхойл.

- $\theta \subseteq R^3$
- $\theta = (w_0, w_1, w_2)$

- i-дэх ажиглалтад зориулсан алдааны функц (loss function)-ийг L_2 алдагдал (L2 loss)-аар тодорхойл.

- $L(y_i, f(x_i) = (y_i - x_i)^2$

- Одоо хамгийн сайн параметрүүд, улмаар хамгийн сайн загварыг олохын тулд эмпирик эрсдэлийг багасгах (empirical risk minimization)-аар энэ эрсдэлийг оновчлох хэрэгтэй. Оновчлолын бодлогыг албан ёсоор бичиж, шийдэхэд шаардлагатай алхамуудыг жагсаа.

- *Find* $\theta_m = (w_0, w_1, w_2)$ *where*
  - $f_m(X) = X \cdot \theta_m$
    - $X = (1, x_1, x_2)$
    - $\theta_m = (w_0, w_1, w_2)$
  - $R_{emp}(f_m) = min$
    - $R_{emp}(f_j) = 1/n * \sum_{i=1} L(y_i, f(x_i)$
    - f_j *in* H
  - $\theta_{t+1} = \theta_t - k * grad$
  - $grad = dR_{emp}(\theta_t)/d\theta = 1/n * \sum_{i=1} dL(y_i, f(x_i)/d\theta$

- $\theta_t = (0, 0, 0)$ *# параметруудаа хамаагүй анхны утгаар эхлүүлнэ*
- *for t in range(100):* *# 100 үеийн турш моделоо шинэчилж үзнэ*
  - $grad = dR_{emp}(\theta_t)/d\theta$ *# тухайн утгуудад эмпирик эрсдэл хэд байгааг бодно*
  - $\theta_t = \theta_t - 0.5 * grad$ *# тухайн утгын градиентын зүгийн дагуу параметруудаа шинэчилнэ*

 # step size 0.5-аар авж үзсэн